

# REGRESIÓN LOGÍSTICA DECISION TREES

CLASE 22

# CLASIFICACIÓN kNN: CONSIDERACIONES

- ✓ Método intuitivo y simple de entender e implementar.
- ✓ Funciona bien para clasificaciones binarias, o multiclase.
- ✓ Sólo tiene un hiperparámetro ( $k$ )
- ✗ El algoritmo es lento para grandes datasets.
- ✗ Funciona bien con pocas variables predictoras, pero falla para problemas de muchas dimensiones.
- ✗ Requiere normalizar los features para evitar problemas de escala.
- ✗ No funciona bien sobre datasets imbalanceados.

# Aprendizaje Supervisado

## Métodos de Clasificación


### Regresión Logística Simple

# CLASIFICACIÓN BINARIA

En el problema de comportamiento de clientes, la clasificación es **binaria**: hay sólo dos outcomes posibles → compra / no compra (1/0).



¿Qué pasaría si tratamos de usar una **regresión lineal**?

- Los resultados para  $Y$  no son coherentes con la definición del outcome.
- Para valores extremos del predictor  $x$ , se obtienen valores de  $Y$  fuera del rango  $[0,1]$ .



# REGRESIÓN LOGÍSTICA SIMPLE

- La situación podría mejorar si tuviéramos una función que transforme la función lineal en algo más apropiado al problema.
- La **Regresión Logística Simple** permite estimar la probabilidad de una variable cualitativa binaria en función de una variable cuantitativa.
- Para ello, se **transforma el valor devuelto por la regresión lineal** empleando una función cuyo resultado está siempre comprendido **entre 0 y 1**.
- Con esto, resuelve los problemas de rango de predicciones y valores posibles de probabilidad del modelo de regresión lineal.




# REGRESIÓN LOGÍSTICA SIMPLE

- La función logística más usada es la **sigmoide**:

$$P(Y = 1|X = x) = p = \frac{e^{(\beta_0 + \beta_1 X)}}{1 + e^{(\beta_0 + \beta_1 X)}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

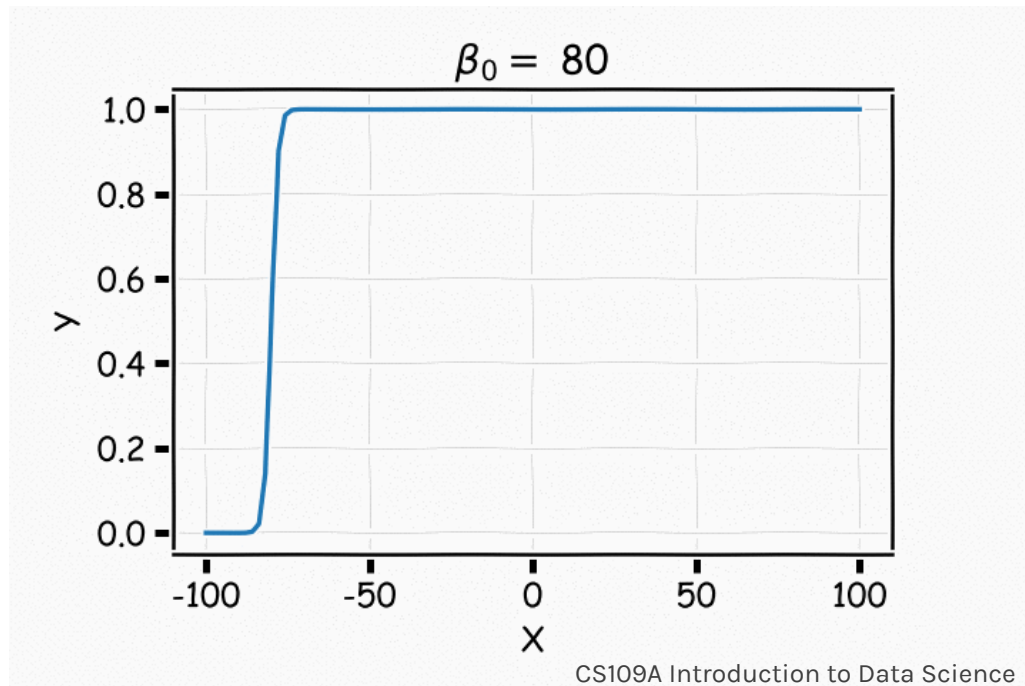
- Interpretación:**  $P(Y = 1|X = x) = p$  es la probabilidad de que la variable cualitativa **Y** adquiriera valor 1, dado que el predictor **X** tiene valor  $x$ .
- El modelo predice  $P(Y = 1|X = x)$  con una curva en forma de **S**.



# REGRESIÓN LOGÍSTICA SIMPLE

$$P(Y = 1|X = x) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$


$\beta_0$  mueve la curva hacia la izquierda o derecha en  $c = -\frac{\beta_0}{\beta_1}$ .



# REGRESIÓN LOGÍSTICA SIMPLE

$$P(Y = 1|X = x) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

$\beta_1$  controla qué tan  
empinada es la forma  $S$   
(~pendiente)





# REGRESIÓN LOGÍSTICA SIMPLE

$$P(Y = 1|X = x) = p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$


- Con un poco de álgebra, el modelo logístico se puede reescribir como:

$$\ln\left(\frac{p}{1-p}\right) = \ln\left(\frac{P(Y=1)}{P(Y=0)}\right) = \beta_0 + \beta_1 X$$

Odds: esto es lo que observamos

- ¿Cómo ajustamos los parámetros  $\beta$  a partir de un conjunto de observaciones?
  - Método de máxima verosimilitud:

$$L(y, \beta) = \sum_{i=1}^n y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i),$$




# REGRESIÓN LOGÍSTICA SIMPLE: MÁXIMA VEROSIMILITUD

- La verosimilitud  $L$  es la versión inversa de la probabilidad condicional  $\rightarrow L(b|A) = P(A|B = b)$
- La variable  $Y$  es una variable aleatoria discreta que tiene probabilidad  $p$  de tomar valor 1 ("éxito"), y probabilidad  $(p - 1)$  de tomar valor 0 (fracaso)  $\rightarrow$  Distribución de Bernoulli
  - $$P(Y = y) = \begin{cases} p & \text{si } y = 1 \\ 1 - p & \text{si } y = 0 \end{cases}$$
  - Esto también se puede escribir como:  $P(Y = y_i|p) = p^{y_i}(1 - p)^{1-y_i}$

Por lo tanto, la verosimilitud de una observación de  $p$  es:

- $$L(p|y_i) = P(Y = y_i|p) = p^{y_i}(1 - p)^{1-y_i}$$
- Dado que las observaciones son independientes, la función de verosimilitud total para  $p$  es:
  - $$L(p|Y) = \prod_i P(Y = y_i) = \prod_i p^{y_i}(1 - p)^{1-y_i}$$
  - Y su logaritmo:  $l(p|Y) = \ln(L(p|Y)) = \sum_i y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)$

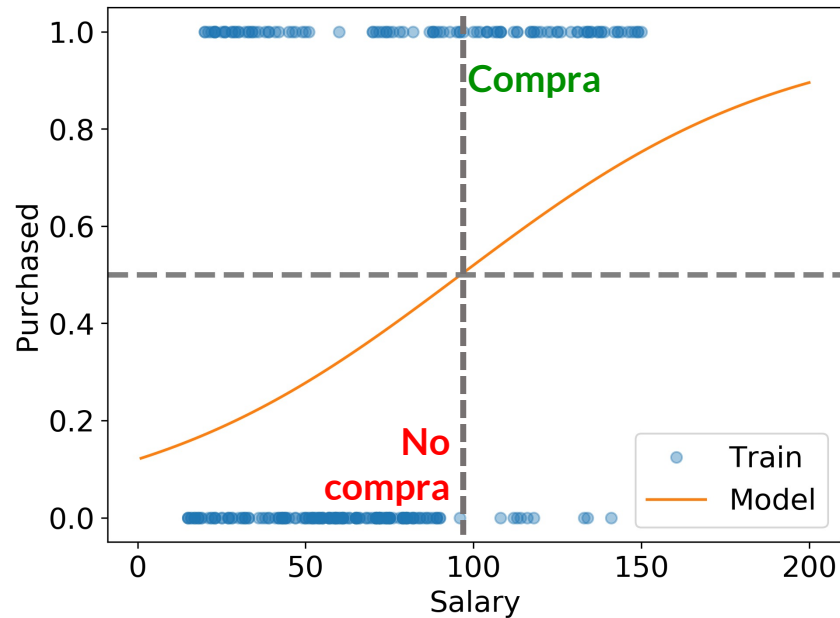


- Reemplazando  $p$ , obtenemos finalmente para la verosimilitud total:
  - $$l(p|Y) = - \sum_i \left[ y_i \log \frac{1}{1+e^{-(\beta_0+\beta_1 x_i)}} + (1 - y_i) \log \left( 1 - \frac{1}{1+e^{-(\beta_0+\beta_1 x_i)}} \right) \right]_i$$
- Para encontrar los valores óptimos de los parámetros  $\beta$ , es necesario maximizar esta expresión (derivar, igualar a cero, y resolver el sistema de ecuaciones mediante métodos iterativos).

# REGRESIÓN LOGÍSTICA SIMPLE PARA CLASIFICACIÓN

$$P(Y = 1|X = x) = p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

- Para una nueva observación  $X = x$ , el modelo de regresión logística entrega la probabilidad  $P(Y = 1|X = x)$ .
- Para clasificar nuevas observaciones asumimos:
  - Si  $P(Y = 1|X = x) \geq 0.5 \rightarrow Y = 1$
  - Si  $P(Y = 1|X = x) < 0.5 \rightarrow Y = 0$
- El rendimiento del clasificador se evalúa usando las métricas comunes de clasificación: exactitud, precisión, sensibilidad,  $F_1$



# REGRESIÓN LOGÍSTICA MÚLTIPLE

- La regresión logística múltiple es una extensión de la regresión logística simple.
- Se basa en los mismos principios que la regresión logística simple pero ampliando el número de predictores.
- Los predictores pueden ser tanto continuos como categóricos:


$$\ln\left(\frac{p}{1-p}\right) = \ln\left(\frac{P(Y=1)}{P(Y=0)}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_J X_J$$

# Aprendizaje Supervisado

## Métodos de Clasificación

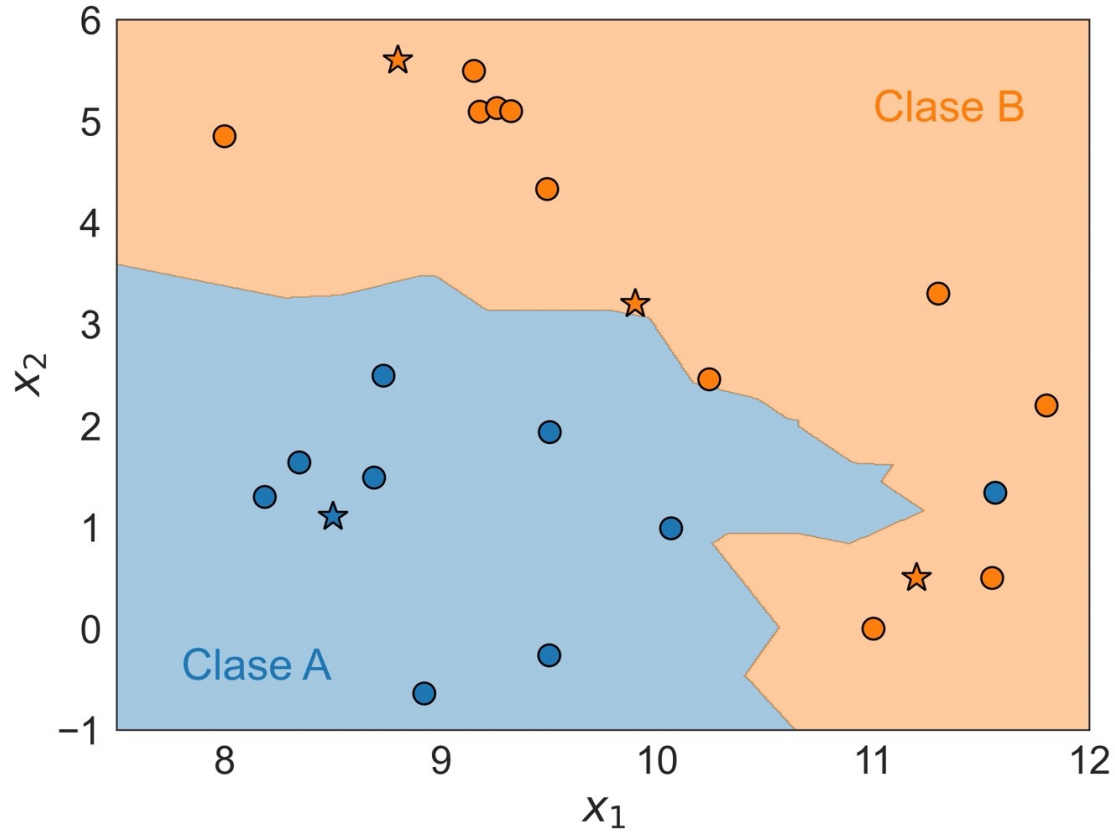
Decision Trees / Árboles de  
Decisión

# Ejemplo



- $\mathcal{D}_{train}$  (clase A)
- $\mathcal{D}_{train}$  (clase B)

# Ejemplo



Clasificación kNN  
(k=3)

# ÁRBOLES DE DECISION / DECISION TREES

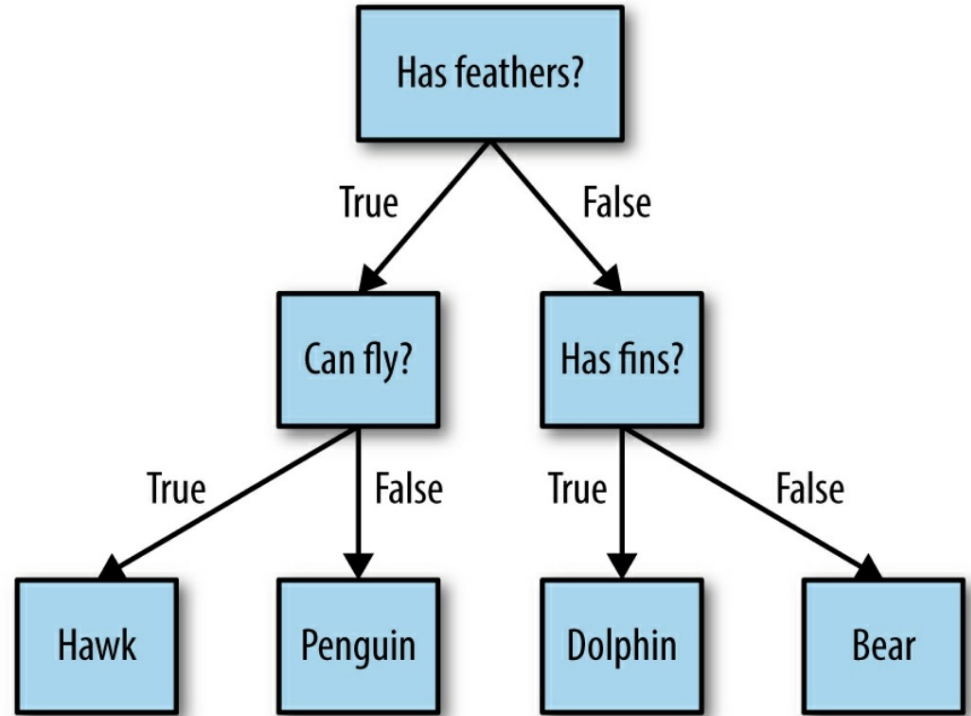
- Los árboles de decisión son modelos de **regresión y clasificación** que se basan en aprender una **jerarquía de preguntas (tests) de tipo if/else** para llegar de la forma más rápida posible a una decisión acertada respecto al valor de la etiqueta de una nueva observación.






# ÁRBOLES DE DECISION / DECISION TREES

- Los árboles de decisión son modelos de **regresión y clasificación** que se basan en aprender una **jerarquía de preguntas (tests) de tipo if/else** para llegar de la forma más rápida posible a una decisión acertada respecto al valor de la etiqueta de una nueva observación.
- Las preguntas pueden ser relativas al valor de una variable numérica o categórica.
- El algoritmo busca sobre todas las posibles pruebas, y selecciona la que es **más informativa** respecto a la variable objetivo.



## Ejemplo

- ¿es  $x_2$  mayor a 2.06?  
y luego,
- ¿es  $x_1$  menor a 10.5?

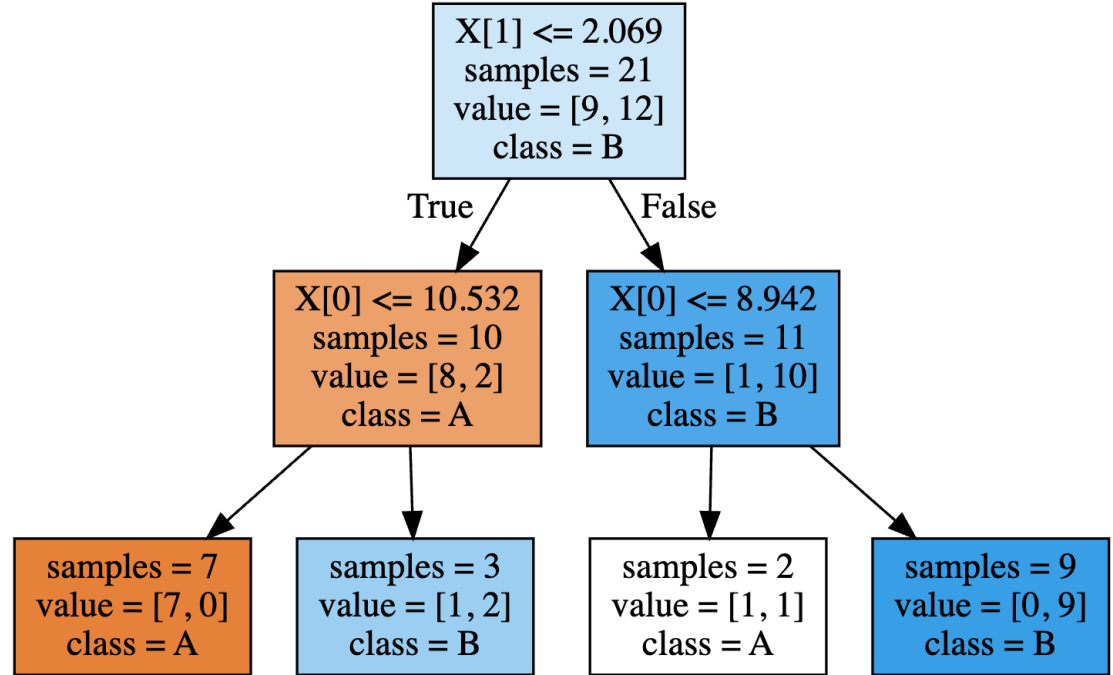


●  $\mathcal{D}_{train}$  (clase A)


●  $\mathcal{D}_{train}$  (clase B)

# Ejemplo

- Para los datos de ejemplo, un árbol de decisión para clasificar las observaciones en clases A o B podría tener la siguiente estructura de tres niveles.
- Cada pregunta concierne **sólo a una variable**, por lo tanto cada pregunta particiona los datos a lo largo de un eje.

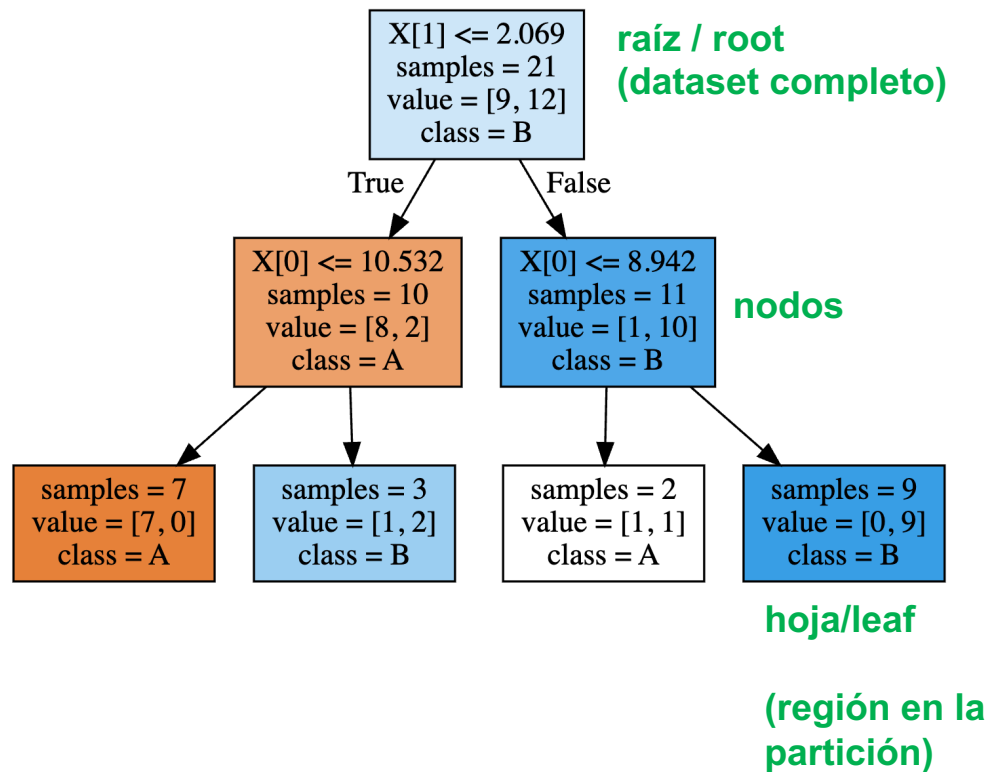


# Ejemplo




●  $D_{train}$  (clase A)

●  $D_{train}$  (clase B)



## Ejemplo



Frontera de decisión en  
el plano  $x_1$ - $x_2$   
(distinta a la obtenida  
con el clasificador kNN)

# COMPLEJIDAD DEL ÁRBOL DE DECISIÓN



Típicamente, la construcción del árbol de decisión continua hasta que todas las hojas son “**puras**”: **contienen sólo una clase objetivo**.

Esto puede llevar a modelos muy complejos → **overfitting**.

- hojas puras → 100% precisión para datos de entrenamiento

Estrategias para prevenir overfitting:

- **Pre-pruning:** cortar tempranamente la creación del árbol
  - Limitar profundidad
  - Limitar n° de hojas
  - Requerir mínimo de puntos en un nodo para dividir
- **Post-pruning:** crear el árbol completo, y colapsar nodos que aportan poca información




# REGRESIÓN LOGÍSTICA SIMPLE: MÁXIMA VEROSIMILITUD

- La verosimilitud  $L$  es la versión inversa de la probabilidad condicional  $\rightarrow L(b|A) = P(A|B = b)$
- La variable  $Y$  es una variable aleatoria discreta que tiene probabilidad  $p$  de tomar valor 1 ("éxito"), y probabilidad  $(p - 1)$  de tomar valor 0 (fracaso)  $\rightarrow$  Distribución de Bernoulli
  - $$P(Y = y) = \begin{cases} p & \text{si } y = 1 \\ 1 - p & \text{si } y = 0 \end{cases}$$
  - Esto también se puede escribir como:  $P(Y = y_i|p) = p^{y_i}(1 - p)^{1-y_i}$

Por lo tanto, la verosimilitud de una observación de  $p$  es:

- $$L(p|y_i) = P(Y = y_i|p) = p^{y_i}(1 - p)^{1-y_i}$$
- Dado que las observaciones son independientes, la función de verosimilitud total para  $p$  es:
  - $$L(p|Y) = \prod_i P(Y = y_i) = \prod_i p^{y_i}(1 - p)^{1-y_i}$$
  - Y su logaritmo: 
$$l(p|Y) = \ln(L(p|Y)) = \sum_i y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)$$



- Reemplazando  $p$ , obtenemos finalmente para la verosimilitud total:
  - $$l(p|Y) = - \sum_i \left[ y_i \log \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_i)}} + (1 - y_i) \log \left( 1 - \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_i)}} \right) \right]_i$$
- Para encontrar los valores óptimos de los parámetros  $\beta$ , es necesario maximizar esta expresión (derivar, igualar a cero, y resolver el sistema de ecuaciones mediante métodos iterativos).